



Università
degli Studi
di Ferrara

— TESI DI LAUREA TRIENNALE · TECNOLOGIE PER L'INDUSTRIA DIGITALE

AI e Customer Experience

Context Engineering, RAG e Function Calling per l'integrazione di agenti conversazionali in sistemi informativi enterprise.

CANDIDATO

Pierluigi Camozzi
Matricola N 196956

RELATORE

Prof. Ing. Lorenzo Marzola

UNIVERSITÀ

Università degli Studi di Ferrara

A.A.

2025 / 2026

— IL PUNTO DI PARTENZA

95%

delle iniziative pilota di GenAI non produce un
impatto economico misurabile.

Fonte: Challapally et al., MIT — NANDA Initiative, 2025

Quasi mai è un problema del modello. È un problema del contesto che gli viene fornito.

Da qui la domanda di questa tesi: **come si progetta il contesto di un agente AI perché funzioni davvero in produzione?**

— OBIETTIVI

Cosa si propone questo lavoro

- Progettare agenti AI integrati con sistemi informativi **enterprise** reali — CRM, ERP, piattaforme di ticketing.
- Validare il ruolo di protocolli aperti — `Model Context Protocol`, `OpenAPI` — e di formati strutturati come `Markdown` e `JSON`.
- Metter alla prova il paradigma del **Context Engineering** su tre casi applicativi reali.
- Applicarlo a due ambiti strategici: **SEO** e **Customer Experience**.

— STRUTTURA DEL LAVORO

Il percorso della tesi

1

Context Engineering & MCP

Le fondamenta architettureali — protocolli, primitive, function calling.

2

Retrieval-Augmented Generation

Leggere la conoscenza aziendale non strutturata.

3

Piattaforme di orchestrazione

Agent Builder OpenAI, ElevenLabs, indigo.ai.

4

Casi realizzati & conclusioni

SEO, rete vendita, voicebot — e il divario tra tecnologia e adozione.

01

Context Engineering & Model Context Protocol

Le fondamenta architettureali di un agente che funziona davvero

— UN CAMBIO DI PARADIGMA

Dal Prompt Engineering al Context Engineering

PROMPT ENGINEERING

Ottimizzare la singola istruzione testuale rivolta al modello. L'unità di lavoro è la stringa.

CONTEXT ENGINEERING

Progettare dati, strumenti, vincoli e flussi conversazionali come un sistema coerente. L'unità di lavoro è l'architettura.

Un modello allo stato dell'arte, con un contesto lacunoso, produce inevitabilmente risultati inesatti.

— LO STANDARD

Model Context Protocol (MCP)

IL PROBLEMA

Integrazioni punto-a-punto: un connettore ad hoc per ogni sistema. Fragili, costose, non scalano — e saturano la finestra di contesto con documentazione irrilevante.

LA RISPOSTA

MCP crea un livello di astrazione **standard** tra agenti AI e fonti di dati, in lettura e in scrittura.

Come l'USB-C standardizza la connessione fisica tra dispositivi, MCP standardizza la connessione logica tra un modello e qualsiasi fonte dati.

①

Discover

l'agente mappa le capacità disponibili sul server



②

Read

recupera le informazioni necessarie alla richiesta



③

Act

modifica, ove autorizzato, lo stato dei sistemi esterni

— ARCHITETTURA

Host → Client → Server

HOST

L'applicazione che incorpora il modello, orchestra il flusso e interpreta gli intenti dell'utente.

CLIENT

Middleware integrato nell'Host: gestisce una singola connessione standardizzata con un server MCP.

SERVER

Applicazione leggera e isolata che espone dati o funzionalità — modulare e riutilizzabile su Host diversi.


Resources dati in lettura, via URI

Prompt template controllati dal server

Tool azioni con effetti collaterali

— DAL RAGIONAMENTO ALL'AZIONE

Function Calling



Il modello ragiona. L'host esegue. — separation of concerns come principio di sicurezza.

— IL CONTRATTO

OpenAPI Specification (Swagger)

- Descrizione **machine-readable** di un'API REST, in `JSON` o `YAML`.
- Endpoint, metodi HTTP, parametri di input, schemi di risposta — in un unico file.
- Permette a un server MCP di **incapsulare** sistemi REST aziendali preesistenti come Tool per l'agente.
- Condivide con i parametri dei Tool MCP lo stesso linguaggio di schema: `JSON Schema`.

02

Retrieval-Augmented Generation

Quando il contesto non è un dato, ma testo non strutturato

— IL MECCANISMO

Come funziona la RAG

- Disaccoppia la **conoscenza** (un database esterno) dalle capacità di **ragionamento** del modello.
- Gli **embedding** mappano il significato del testo in uno spazio vettoriale.
- I frammenti più pertinenti vengono recuperati e iniettati nel contesto al momento della query.

A differenza del fine-tuning, il modello resta inalterato: la conoscenza si inietta a ogni singola interrogazione.

— IL CRITERIO

Quando conviene usare la RAG — tre condizioni congiunte

CAPIENZA

Il corpus eccede la finestra di contesto del modello.

LOCALITÀ

La risposta è concentrata in pochi frammenti, non aggregata su migliaia di documenti.

NATURA SEMANTICA

La pertinenza è di significato — non un dato strutturato, temporale o quantitativo.

Dato esatto → API diretta · Azione → Tool · Sintesi globale → aggregazione, non RAG pura.

— DUE REGIMI DI CONOSCENZA

RAG e Tool/MCP: complementari, non alternativi

RAG

Conoscenza statica vettorializzata. L'agente **legge** testo non strutturato per similarità semantica.

MCP / TOOL

Accesso in tempo reale ai sistemi sorgente. L'agente **legge e scrive** dati vivi.

Non sono mutuamente esclusivi: un retriever RAG può a sua volta essere esposto come Tool MCP.

I casi Lenovo e Plenitude, tra poco, ne sono la prova empirica.

03

Casi Realizzati

Tre stadi di complessità crescente del Context Engineering

— LA PROGRESSIONE

Dal prompt statico all'orchestrazione transazionale

1

Younited — Google AI Studio

Agente **all-prompt** per la produzione di contenuti SEO.

2

Lenovo — indigo.ai

RAG + **multi-agente** per l'assistenza alla rete vendita.

3

Plenitude «Luce» — indigo.ai + ElevenLabs

Function calling in tempo reale su un voicebot.

— CASO 1 — SEO

Younited — Pipeline SEO «all-prompt»

1→5

Brand → SEO → Brief → Link → Generazione

cinque fasi sequenziali, contesto iniettato staticamente nel prompt

−25/30% tempo di produzione

Query Fan-Out a scala industriale

Conformità **E-E-A-T / YMYL**

Nessun tool, nessuna RAG: tutta l'intelligenza è nella catena di prompt e nei delimitatori.

— CASO 2 — RETE VENDITA

Lenovo — Assistente RAG multi-agente

ARCHITETTURA

Mother Agent qualifica il bisogno → instrada a 4 sub-agenti per fascia di prezzo (Essential, SMB, ThinkPad Classic, Workstation).

PIPELINE DATI

Excel cleaning → Markdown (Reducto) → Knowledge Base vettoriale indigo.ai.

Gli SKU venivano allucinati: il chunking spezzava la scheda prodotto. Soluzione → chunking guidato dalla struttura Markdown, codice e prezzo nello stesso vettore.

~80% automation rate

— CASO 3 — VOICEBOT

Plenitude «Luce» — Function Calling in tempo reale

- Nessuna KB statica: backend `Swagger` interrogato live — `POST /lookup`, `POST /api/lettura`.
- L'agente legge e scrive: da «consiglia» a «opera».
- Stack vocale: `STT` → LLM (indigo.ai, GPT-4.1) → `TTS` (ElevenLabs).
- Regole di business: disambiguazione multi-fornitura, filtro contatori teleletti.

~85% automation rate

— SINTESI

Tre casi, tre paradigmi

CASO	CONOSCENZA	AZIONE	PARADIGMA
Younited	Statica, nel prompt	Nessuna	All-prompt
Lenovo	KB vettoriale	Lettura	RAG + multi-agente
Plenitude	API in tempo reale	Lettura + scrittura	Function calling

04

Conclusioni

Maturità tecnica e divario di adozione

— SUL PIANO TECNICO

La tecnologia è pronta

- Automation rate dell'**80–85%** nei casi reali presentati.
- **MCP** + **OpenAPI**: fondamenta interoperative solide.
- Piattaforme industrialmente mature — Agent Builder OpenAI, ElevenLabs, indigo.ai.
- Costo unitario dell'inferenza in costante calo.

— SUL PIANO STRATEGICO

Il vero collo di bottiglia è organizzativo

MIT, 2025

95% delle iniziative pilota non produce un impatto economico misurabile.

MCKINSEY, 2025

88% usa AI, ma solo **1/3** scala enterprise-wide — solo **~6%** è «high performer».

La barriera non è il costo o la complessità della tecnologia, ma la difficoltà delle organizzazioni di assumere decisioni percepite come destabilizzanti.

32% delle aziende prevede una contrazione dell'organico nei prossimi 12 mesi — McKinsey, 2025

Grazie per l'attenzione

Pierluigi Camozzi — Tesi di Laurea Triennale
Università degli Studi di Ferrara